第一章

统计学习方法概论

袁春 清华大学深圳研究生院 李航 华为诺亚方舟实验室

目录

- 1. 统计学习
- 2. 监督学习
- 3. 统计学习三要素
- 4. 模型评估与模型选择
- 5. 正则化与交叉验证
- 6. 泛化能力
- 7. 生成模型与判别模型
- 8. 分类问题
- 9. 标注问题
- 10. 回归问题

一、统计学习

∞统计学习的对象

- ∞data: 计算机及互联网上的各种数字、文字、图像、视频、音频数据以及它们的组合。
- 致据的基本假设是同类数据具有一定的统计规律性。
- ∞统计学习的目的
 - ∞用于对数据(特别是未知数据)进行预测和分析。

统计学习

∞统计学习的方法

80分类:

- Supervised learning
- Unsupervised learning
 ■
- Semi-supervised learning
- Reinforcement learning

∞监督学习:

- ≥ 训练数据 training data
- ≥ 模型 model ----- 假设空间 hypothesis
- ≥> 评价准则 evaluation criterion ------ 策略 strategy
- ∞ 算法 algorithm

统计学习

- ∞统计学习的研究:
 - ∞ 统计学习方法
 - ∞ 统计学习理论(统计学习方法的有效性和效率和基本理论)
 - ∞ 统计学习应用

二、监督学习

- Instance, feature vector, feature space
- ∞输入实例x的特征向量:

$$x = (x^{(1)}, x^{(2)}, \dots, x^{(i)}, \dots, x^{(n)})^{\mathrm{T}}$$

≥ x⁽ⁱ⁾与x_i不同,后者表示多个输入变量中的第i个

$$x_i = (x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(n)})^T$$

∞训练集:

$$T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}\$$

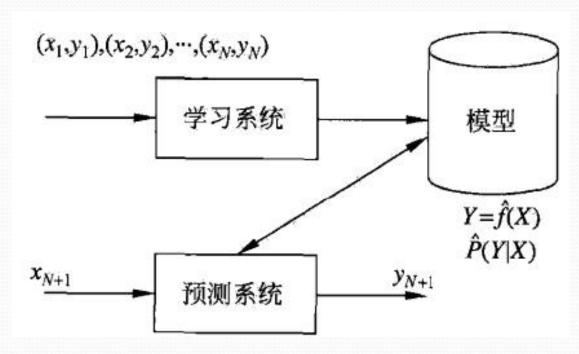
- ∞输入变量和输出变量:
 - 20分类问题、回归问题、标注问题

监督学习

- ∞联合概率分布
 - ∞假设输入与输出的随机变量X和Y遵循联合概率分布P(X,Y)
 - ∞P(X,Y)为分布函数或分布密度函数
 - 20对于学习系统来说,联合概率分布是未知的,
 - ∞训练数据和测试数据被看作是依联合概率分布P(X,Y)独立同分布产生的。
- ∞假设空间
 - ∞监督学习目的是学习一个由输入到输出的映射, 称为模型
 - ∞模式的集合就是假设空间(hypothesis space)
 - ∞概率模型:条件概率分布P(Y|X), 决策函数: Y=f(X)

监督学习

∞问题的形式化



$$y_{N+1} = \arg \max_{y_{N+1}} \hat{P}(y_{N+1} \mid x_{N+1})$$
$$y_{N+1} = \hat{f}(x_{N+1})$$

三、统计学习三要素

方法=模型+策略+算法

₩模型:

∞决策函数的集合: $\mathcal{F} = \{f \mid Y = f(X)\}$

xx参数空间

$$\mathcal{F} = \{ f \mid Y = f_{\theta}(X), \theta \in \mathbf{R}^n \}$$

∞条件概率的集合:

$$\mathcal{F} = \{P \mid P(Y \mid X)\}$$

so参数空间

$$\mathcal{F} = \{P \mid P_{\theta}(Y \mid X), \theta \in \mathbf{R}^n\}$$

%策略

∞损失函数:一次预测的好坏

∞风险函数: 平均意义下模型预测的好坏

∞o-1损失函数 o-1 loss function

$$L(Y, f(X)) = \begin{cases} 1, & Y \neq f(X) \\ 0, & Y = f(X) \end{cases}$$

∞平方损失函数 quadratic loss function

$$L(Y, f(X)) = (Y - f(X))^2$$

∞绝对损失函数 absolute loss function

$$L(Y, f(X)) = |Y - f(X)|$$

%策略

∞对数损失函数 logarithmic loss function 或对数似然损失 函数 loglikelihood loss function

$$L(Y, P(Y \mid X)) = -\log P(Y \mid X)$$

∞损失函数的期望

$$R_{\exp}(f) = E_P[L(Y, f(X))] = \int_{X \times Y} L(y, f(x)) P(x, y) dxdy$$

∞风险函数 risk function 期望损失 expected loss

∞由P(x,y)可以直接求出P(x|y),但不知道,

$$T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}\$$

∞经验风险 empirical risk ,经验损失 empirical loss

$$R_{\text{cmp}}(f) = \frac{1}{N} \sum_{i=1}^{N} L(y_i, f(x_i))$$

∞策略: 经验风险最小化与结构风险最小化

∞经验风险最小化最优模型

$$\min_{f \in \mathcal{F}} \frac{1}{N} \sum_{i=1}^{N} L(y_i, f(x_i))$$

- ∞当样本容量很小时,经验风险最小化学习的效果未必很好,会产生"过拟合over-fitting"
- 验结构风险最小化 structure risk minimization,为防止过 拟合提出的策略,等价于正则化(regularization),加 入正则化项regularizer,或罚项 penalty term:

$$R_{\text{arm}}(f) = \frac{1}{N} \sum_{i=1}^{N} L(y_i, f(x_i)) + \lambda J(f)$$

∞求最优模型就是求解最优化问题:

$$\min_{f \in \mathcal{F}} \frac{1}{N} \sum_{i=1}^{N} L(y_i, f(x_i)) + \lambda J(f)$$

≥算法:

- ∞如果最优化问题有显式的解析式,算法比较简单
- 20但通常解析式不存在,就需要数值计算的方法

四、模型评估与模型选择

∞训练误差,训练数据集的平均损失

$$R_{\text{emp}}(\hat{f}) = \frac{1}{N} \sum_{i=1}^{N} L(y_i, \hat{f}(x_i))$$

∞测试误差,测试数据集的平均损失

$$e_{\text{test}} = \frac{1}{N'} \sum_{i=1}^{N'} L(y_i, \hat{f}(x_i))$$

∞损失函数是o-1 损失时:

$$e_{\text{test}} = \frac{1}{N'} \sum_{i=1}^{N'} I(y_i \neq \hat{f}(x_i))$$

∞测试数据集的准确率:

$$r_{\text{test}} = \frac{1}{N'} \sum_{i=1}^{N'} I(y_i = \hat{f}(x_i))$$

模型评估与模型选择

- ∞过拟合与模型选择
- ≫假设给定训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$

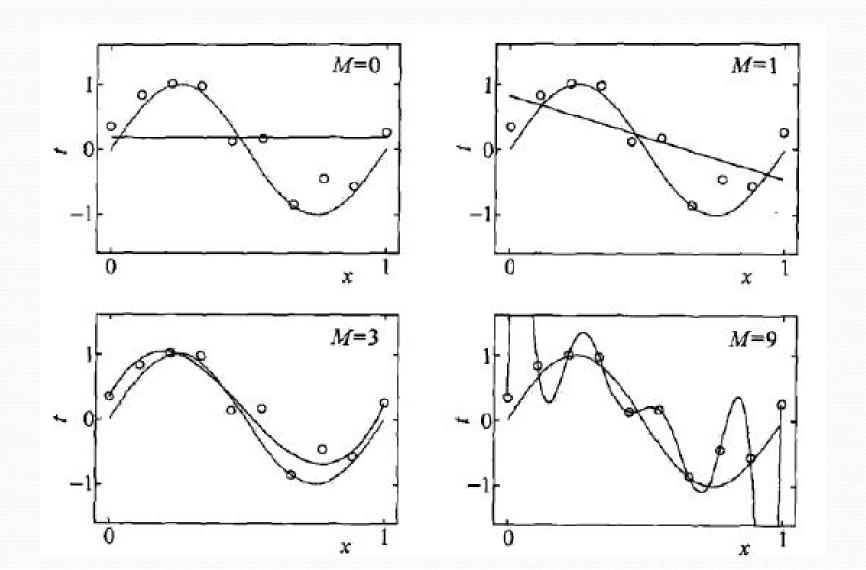
$$f_M(x, w) = w_0 + w_1 x + w_2 x^2 + \dots + w_M x^M = \sum_{j=0}^M w_j x^j$$

∞经验风险最小:

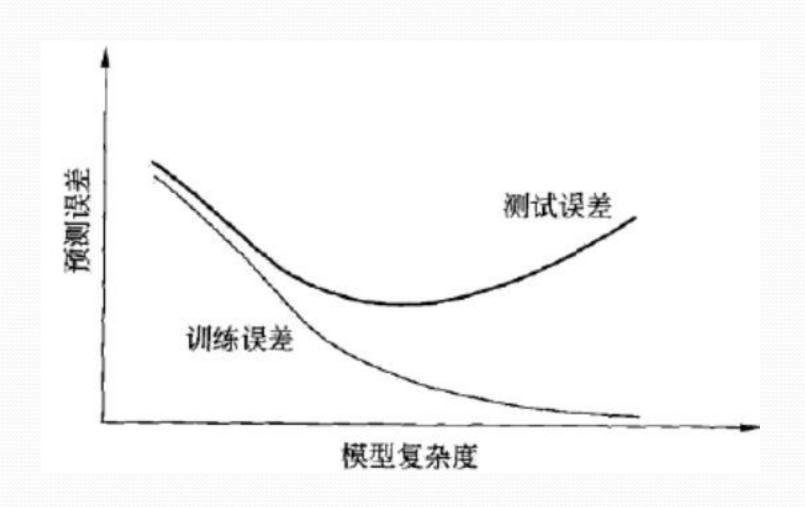
$$L(w) = \frac{1}{2} \sum_{i=1}^{N} (f(x_i, w) - y_i)^2 \qquad L(w) = \frac{1}{2} \sum_{i=1}^{N} \left(\sum_{j=0}^{M} w_j x_i^j - y_i \right)^2$$

$$w_{j} = \frac{\sum_{i=1}^{N} x_{i} y_{i}}{\sum_{i=1}^{N} x_{i}^{j+1}}, \quad j = 0, 1, 2, \dots, M$$

模型评估与模型选择



模型评估与模型选择



五、正则化与交叉验证

∞正则化一般形式:

$$\min_{f \in \mathcal{F}} \frac{1}{N} \sum_{i=1}^{N} L(y_i, f(x_i)) + \lambda J(f)$$

∞回归问题中:

$$L(w) = \frac{1}{N} \sum_{i=1}^{N} (f(x_i; w) - y_i)^2 + \frac{\lambda}{2} ||w||^2$$

$$L(w) = \frac{1}{N} \sum_{i=1}^{N} (f(x_i; w) - y_i)^2 + \lambda ||w||_1$$

正则化与交叉验证

∞交叉验证:

- ∞训练集 training set: 用于训练模型
- ∞验证集 validation set: 用于模型选择
- ∞测试集 test set: 用于最终对学习方法的评估
- ∞简单交叉验证
- ∞S折交叉验证
- 80留一交叉验证

六、泛化能力 generalization ability

≫泛化误差 generalization error

$$R_{\exp}(\hat{f}) = E_P[L(Y, \hat{f}(X))] = \int_{X \times Y} L(y, \hat{f}(X)) P(x, y) dxdy$$

- ∞泛化误差上界
 - ∞比较学习方法的泛化能力-----比较泛化误差上界
 - ∞性质: 样本容量增加, 泛化误差趋于o
 - 80 假设空间容量越大, 泛化误差越大
- ≫二分类问题 $X \in \mathbb{R}^n$, $Y \in \{-1,+1\}$
- ∞期望风险和经验风险

$$R(f) = E[L(Y, f(X))] \qquad \hat{R}(f) = \frac{1}{N} \sum_{i=1}^{N} L(y_i, f(x_i))$$

泛化能力 generalization ability

∞经验风险最小化函数:

$$f_N = \arg\min_{f \in \mathcal{F}} \hat{R}(f)$$

∞泛化能力:

$$R(f_N) = E[L(Y, f_N(X))]$$

定理: 泛化误差上界,二分类问题,当假设空间是有限个函数的结合 $\mathcal{F} = \{f_1, f_2, \dots, f_n\}$,对任意一个函数f, 至少以概率1-δ,以下不等式成立:

$$R(f) \leq \hat{R}(f) + \varepsilon(d, N, \delta)$$

$$\varepsilon(d, N, \delta) = \sqrt{\frac{1}{2N} \left(\log d + \log \frac{1}{\delta} \right)}$$

七、生成模型与判别模型

∞监督学习的目的就是学习一个模型:

∞决策函数:

$$Y = f(X)$$

∞条件概率分布:

≥ 生成方法Generative approach 对应生成模型: generative model,

$$P(Y \mid X) = \frac{P(X,Y)}{P(X)}$$

∞朴素贝叶斯法和隐马尔科夫模型

生成模型与判别模型

- ≥>判别方法由数据直接学习决策函数f(X)或条件概率分布 P(Y|X)作为预测的模型,即判别模型
- ≥ Discriminative approach对应discriminative model

$$Y = f(X)$$

P(Y|X)

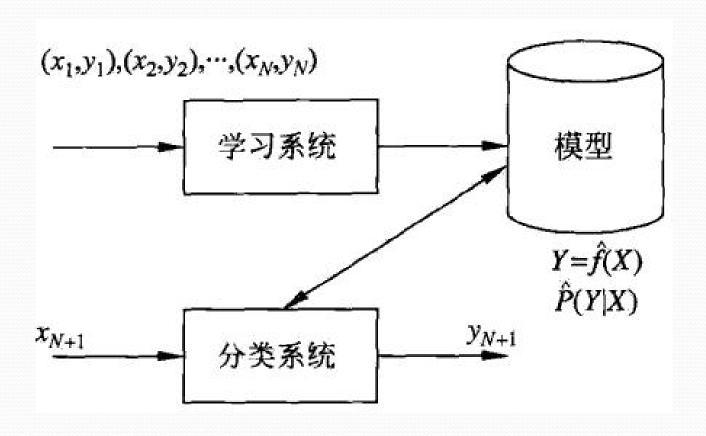
≫K近邻法、感知机、决策树、logistic回归模型、最大熵模型、支持向量机、提升方法和条件随机场。

生成模型与判别模型

∞各自优缺点:

- №生成方法:可还原出联合概率分布P(X,Y),而判别方法不能。 生成方法的收敛速度更快,当样本容量增加的时候,学到的 模型可以更快地收敛于真实模型;当存在隐变量时,仍可以 使用生成方法,而判别方法则不能用。
- ∞判别方法:直接学习到条件概率或决策函数,直接进行预测,往往学习的准确率更高;由于直接学习Y=f(X)或P(Y|X),可对数据进行各种程度上的抽象、定义特征并使用特征,因此可以简化学习过程。

八、分类问题



分类问题

∞二分类评价指标

- ∞TP true positive
- ∞FN false negative
- ∞FP false positive
- ∞TN true negative

∞精确率

$$P = \frac{TP}{TP + FP}$$

∞召回率

$$R = \frac{TP}{TP + FN}$$

≫Fı值

$$\frac{2}{F_1} = \frac{1}{P} + \frac{1}{R}$$
 $F_1 = \frac{2TP}{2TP + FP + FN}$

九、标注问题

≫标注: tagging, 结构预测: structure prediction

∞输入:观测序列,输出:标记序列或状态序列

∞学习和标注两个过程

≫训练集:
$$T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$$

≫观测序列:
$$x_i = (x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(n)})^T$$
, $i = 1, 2, \dots, N$

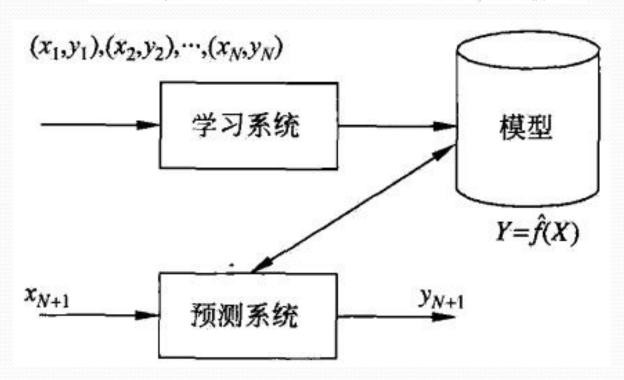
≫输出标记序列:
$$y_i = (y_i^{(1)}, y_i^{(2)}, \dots, y_i^{(n)})^T$$

≫模型:条件概率分布 $P(Y^{(1)},Y^{(2)},...,Y^{(n)}|X^{(1)},X^{(2)},...,X^{(n)})$

十、回归问题

- №回归模型是表示从输入变量到输出变量之间映射的函数. 回归问题的学习等价于函数拟合。
- >>学习和预测两个阶段

≫训练集:
$$T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$$



回归问题

- ∞例子:
- ≫标记表示名词短语的"开始"、"结束"或"其他" (分别以B, E, O表示)
- ※輸入: At Microsoft Research, we have an insatiable curiosity and the desire to create new technology that will help define the computing experience.
- 知知: At/O Microsoft/B Research/E, we/O have/O an/O insatiable/6 curiosity/E and/O the/O desire/BE to/O create/O new/B technology/E that/O will/O help/O define/O the/O computing/B experience/E.

回归问题

№回归学习最常用的损失函数是平方损失函数,在此情况下,回归问题可以由著名的最小二乘法(least squares) 求解。

∞股价预测

Q & A